NA14 Regresija

Ivan Slapničar

3. prosinca 2018.

1 Regresija

Regresija je provlačenje funkcije f koja ovisi o n parametara kroz točke (x_i, y_i) , i = 1, 2, ..., m, pri čemu je m > n, tako da se *minimizira norma odstupanja*:

$$||f(x_i)-y_i||_{1,2,\infty}\to\min$$
.

Regresija u smislu najmanjih kvadrata je

$$||f(x_i) - y_i||_2 \rightarrow \min.$$

Kada je funkcija f pravac,

$$f(x) = kx + l$$

radi se o linearnoj regresiji. U tom slučaju dobije se sustav linearnih jednadžbi

$$kx_i + l = y_i, \quad i = 1, 2, \dots, m.$$

Ukoliko sve točke ne leže na istom pravcu, sustav nije rješiv pa se računa kvadratična prilagodba.

1.1 Primjer

Provucimo pravac kroz točke (x_i, y_i) , i = 1, ..., m, i izračunajmo kvalitetu prilagodbe.

4.0 1.0 6.0 1.0 7.0 1.0

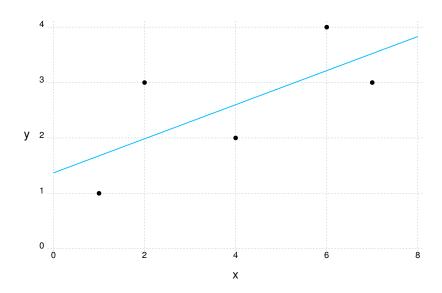
In [2]: # Koeficijenti $kl=A\y$

Out[2]: 2-element Array{Float64,1}: 0.30769230769230765 1.3692307692307688

Out[4]: 1.3692307692307688:0.02486402486402486:3.83076923076923

In [5]: plot(layer(x=x,y=y),layer(x=xx,y=yy,Geom.line))

Out[5]:



Out[6]: 0.5147667768205637

1.2 Primjer - Kvadratična regresija

Kroz točke možemo provući i kvadratni polinom $y = ax^2 + bx + c$. Ukoliko sve točke ne leže na istoj paraboli, sustav linearnih jednadžbi

$$ax_i^2 + bx_i + c = y_i, \quad i = 1, ..., m,$$

nije rješiv pa računamo kvadratičnu prilagodbu.

```
In [7]: n=5
        x=collect([1,2,4,5,6])
        y=collect([0,1,4,8,14])
        A=[x.^2 \times ones(n)]
Out[7]: 5×3 Array{Float64,2}:
          1.0 1.0 1.0
         4.0 2.0 1.0
         16.0 4.0 1.0
         25.0 5.0 1.0
         36.0 6.0 1.0
In [8]: # Koeficijenti polinoma
        abc=A\y
Out[8]: 3-element Array{Float64,1}:
          0.6899350649350633
         -2.1607142857142745
          1.8636363636363449
In [9]: # Nacrtajmo točke i parabolu
        xx=range(0,stop=7,length=100)
        yy=abc[1]*(xx.^2)+abc[2]*xx.+abc[3]
Out[9]: 100-element Array{Float64,1}:
          1.8636363636363449
          1.7143079092114726
          1.5718781014924095
          1.4363469404791553
          1.3077144261717106
          1.1859805585700753
          1.071145337674249
          0.963208763484232
          0.8621708360000242
          0.7680315552216255
          0.6807909211490362
          0.6004489337822561
```

```
0.5270055931212854

:

15.130751964085285

15.588504419771626

16.053155522163774

16.524705271261727

17.0031536670655

17.488500709575078

17.980746398790455

18.479890734711653

18.985933717338664

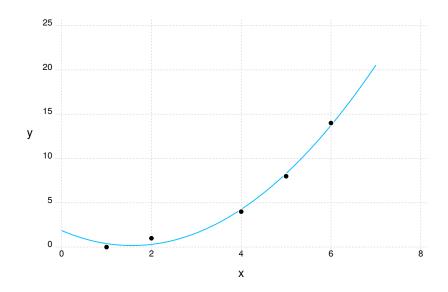
19.498875346671472

20.01871562271009
```

20.545454545454525

In [10]: plot(layer(x=x,y=y),layer(x=xx,y=yy,Geom.line))

Out[10]:



In [11]: # Kvaliteta prilagodbe
 q=sqrt(norm(A*abc-y)/norm(y))

Out[11]: 0.23696295042459756

1.3 Primjer - Rast svjetske populacije

Dosadašnji rast populacije (u milionima) da je u sljedećoj tablici (vidi http://en.wikipedia.org/wiki/World_population).

Aproksimirajmo rast populacije eksponencijalnom funkcijom

$$P(t) = Ce^{kt}$$

i predvidimo populaciju 2050. godine.

Sustav jednadžbi

$$Ce^{kt_i} = P_i, \quad i = 1, 2, \dots, 9$$

logaritmiranjem prelazi u sustav linearnih jednadžbi

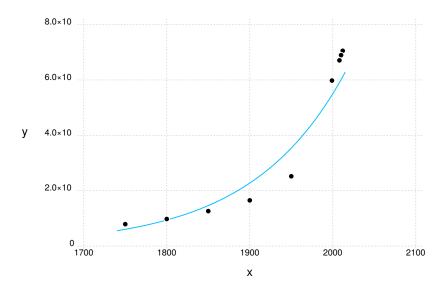
$$k t_i + \ln C = \ln P_i$$
.

Sve točke ne leže na istoj krivulji pa sustav nije rješiv i računamo kvadratičnu prilagodbu.

```
In [12]: n=9
         t=collect([1750,1800,1850,1900,1950,1999,2008,2010,2012])
         P=collect([791,978,1262,1650,2521,5978,6707,6896,7052])
         A=[tones(9)]
         kC=A \setminus log.(P)
Out[12]: 2-element Array{Float64,1}:
           0.008834419929650809
          -9.055914228293918
In [13]: # Vrijednosti na krivulji
         Pv=exp.(kC[2]).*exp.(kC[1].*t)
Out[13]: 9-element Array{Float64,1}:
           604.4510245115797
           940.152075924994
          1462.2953556581206
          2274.427469700024
          3537.6029164763945
          5453.927176892081
          5905.273182327283
          6010.539738912149
```

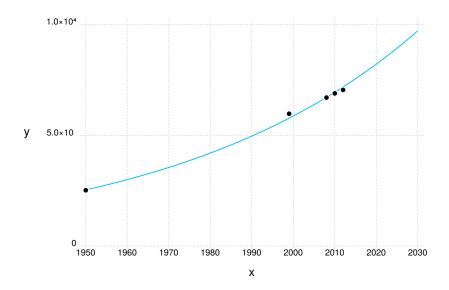
6117.682762104567

Out[14]:



Out[15]: 8558.212502172595

Izračunata predikcija je manja od one u tablici. Ako se ograničimo na razdoblje od 1950 godine imamo:



In [17]: P2050=exp(kC[2])*exp(kC[1]*2050)

Out[17]: 13592.0770645014